


INTELIGÊNCIA ARTIFICIAL

Estes protocolos ajudarão os agentes de IA a navegar por nossas complexas vidas



MIT Technology Review
Peter Hall

Anthropic, Google e outras empresas estão desenvolvendo maneiras melhores para os sistemas interagirem com nossos programas e entre si, mas ainda há muito a ser feito



Um número crescente de empresas está lançando agentes de IA capazes de realizar tarefas em seu nome, como ações relacionadas a enviar e-mails, criar documentos ou editar bancos de dados. No entanto, as primeiras impressões sobre esses sistemas têm sido, na melhor das hipóteses, variadas, pois eles enfrentam dificuldades para interagir com os diferentes componentes de nossas vidas digitais.

Parte do problema é que ainda estamos construindo a infraestrutura necessária para ajudar esses sistemas a navegar pelo mundo. Se queremos que cumpram tarefas para nós, precisamos fornecer as ferramentas adequadas, garantindo também que usem esse poder de maneira responsável.

A Anthropic e o Google estão entre as empresas e grupos que trabalham justamente nesse sentido. Ao longo do último ano, ambas desenvolveram protocolos que buscam definir como esses sistemas devem interagir entre si e com o mundo ao redor. Esses protocolos podem facilitar o controle de outros programas, como e-mails e aplicativos de anotações.

A razão disso está nas interfaces de programação de aplicativos (APIs), que são as conexões entre computadores ou programas que governam grande parte do nosso mundo online. As APIs atualmente respondem a solicitações com informações padronizadas. No entanto, os modelos de IA não foram feitos para funcionar exatamente da mesma forma a cada vez. A própria aleatoriedade que os torna expressivos e aptos as conversas também dificulta que eles tanto chamem uma API quanto compreendam a resposta.

O MCP tenta padronizar a forma como os agentes de IA interagem com o mundo por meio de diversos programas, e já é bastante popular. Um agregador da web para servidores MCP (basicamente, os portais para diferentes programas ou ferramentas que os agentes podem acessar) lista mais de 15 mil servidores atualmente.

Entender como governar a interação entre os agentes de IA é, provavelmente, um desafio ainda maior, e é esse o objetivo do protocolo Agent2Agent (A2A), apresentado pelo Google em abril. Enquanto o MCP traduz solicitações entre palavras e código, o A2A tenta moderar as trocas entre agentes, o que é “um próximo passo essencial para a indústria avançar além de agentes de propósito único”, escreveu Rao Surapaneni, que trabalha com o A2A na Google Cloud, em um e-mail para a MIT Technology Review.

O Google afirma que 150 empresas já fizeram parcerias com ele para desenvolver e adotar o A2A, incluindo Adobe e Salesforce. De forma geral, tanto o MCP quanto o A2A orientam um agente de IA sobre o que ele deve fazer, o que ele deve fazer em seguida e o que ele não deve fazer para garantir uma interação segura com outros serviços. De certa forma, são complementares. Cada agente em uma interação A2A pode estar usando o MCP para buscar informações que o outro solicita.

No entanto, Chu destaca que ainda estamos “definitivamente no início” do desenvolvimento do MCP, e o roadmap do A2A ainda lista várias tarefas a serem concluídas. Identificamos as três principais áreas de crescimento para o MCP, o A2A e outros protocolos de agentes: segurança, abertura e eficiência.

O que esses protocolos devem dizer sobre segurança?

Pesquisadores e desenvolvedores ainda não compreendem totalmente como os modelos de IA funcionam, e novas vulnerabilidades estão sendo descobertas o tempo todo. Para aplicações de IA no estilo chatbot, ataques maliciosos podem fazer com que os modelos realizem todo tipo de coisa errada, incluindo regurgitar dados de treinamento e proferir insultos. Mas, para agentes de IA, que interagem com o mundo em nome de alguém, as possibilidades são muito mais arriscadas.

Por exemplo, um agente de IA, feito para ler e enviar e-mails em nome de alguém, já demonstrou ser vulnerável ao que é conhecido como ataque de injeção de prompt indireto. Essencialmente, um e-mail poderia ser escrito de forma que sequestrasse o modelo de IA e causasse seu mau funcionamento. Depois, se esse agente tiver acesso aos arquivos do usuário, ele poderia ser instruído a enviar documentos privados para quem está atacando.

Alguns pesquisadores acreditam que protocolos como o MCP deveriam impedir que os agentes realizassem ações prejudiciais como essa. No entanto, isso não acontece no momento. “Basicamente, ele não tem nenhum design de segurança”, diz Zhaorun. Chen, estudante de doutorado da Universidade de Chicago, que trabalha com segurança de agentes de IA e usa servidores MCP.

Bruce Schneier, pesquisador de segurança e ativista, é cético quanto à capacidade de protocolos como o MCP de reduzir os riscos inerentes à IA e se preocupa que dar mais poder a essa tecnologia só aumente sua capacidade de causar danos no mundo real.

“Simplesmente não temos boas respostas sobre como garantir a segurança disso”, diz Schneier. “Vai se tornar um verdadeiro poço de insegurança muito rápido.”

Outros são mais otimistas. O design de segurança poderia ser adicionado ao MCP e ao A2A de maneira semelhante à forma como é feito para protocolos de internet, como o HTTPS (embora a natureza dos ataques aos sistemas de IA seja bem diferente). Chen e a Anthropic acreditam que padronizar protocolos como o MCP e o A2A pode ajudar a tornar mais fácil detectar e resolver problemas de segurança, mesmo como estão.

Chen usa o MCP em sua pesquisa para testar os papéis que diferentes programas podem desempenhar em ataques, a fim de entender melhor as vulnerabilidades. Chu, da Anthropic, acredita que essas ferramentas poderiam permitir que as empresas de segurança cibernética lidassem com ataques a agentes de forma mais eficiente, porque seria mais fácil descobrir quem enviou o quê.

Até que ponto esses sistemas devem ser abertos?

Embora o MCP e o A2A sejam dois dos modelos mais populares disponíveis hoje, muitos outros estão em desenvolvimento. Grandes empresas como Cisco e IBM estão criando suas próprias soluções, enquanto outros grupos apresentaram designs diferentes, como o Agora, desenvolvido por pesquisadores da Universidade de Oxford, que aprimora a comunicação entre sistemas e serviços, transformando a linguagem humana em dados estruturados em tempo real.

Muitos desenvolvedores esperam que, eventualmente, haja um registro de sistemas seguros e confiáveis para navegar

na proliferação de agentes e ferramentas. Outros, incluindo Chen, desejam que os usuários possam avaliar diferentes serviços em algo como o Yelp para ferramentas de agentes de IA. Alguns protocolos mais nichados chegaram a construir blockchains sobre o MCP e o A2A, para que os servidores possam provar que não são apenas spam.

Tanto o MCP quanto o A2A são de código aberto, o que é comum para padrões em potencial, pois permite que outros trabalhem no desenvolvimento desses sistemas. Isso pode ajudar os protocolos a se desenvolverem de forma mais rápida e transparente.

“Se construirmos algo juntos, gastamos menos tempo no total, porque não precisamos reinventar a roda a cada vez”, diz David Nalley, que lidera a experiência de desenvolvedor na Amazon Web Services e trabalha com muitos sistemas de código aberto, incluindo A2A e MCP.

O Google doou o A2A para a Linux Foundation, uma organização sem fins lucrativos que orienta projetos de código aberto, em junho, e a Amazon Web Services agora é uma das colaboradoras do projeto. Com a administração da fundação, os desenvolvedores que trabalham no A2A (incluindo funcionários do Google e muitos outros) têm voz sobre como ele deve evoluir.

O MCP, por outro lado, é de propriedade da Anthropic e licenciado gratuitamente. Esse é um ponto de discordância para alguns defensores do código aberto, que desejam que outros também tenham voz sobre como a base de código é desenvolvida.

“Há um risco aumentado quando uma única pessoa ou uma única entidade tem controle

absoluto”, diz Nalley. Ele afirma que a maioria das pessoas preferiria que vários grupos tivessem um “lugar à mesa” para garantir que esses protocolos atendam aos melhores interesses de todos.

No entanto, Nalley acredita que a Anthropic está agindo de boa fé. Sua licença, segundo ele, é extremamente permissiva, permitindo que outros grupos criem suas próprias versões modificadas do código (um processo conhecido como “forking”, quando se cria uma cópia para desenvolvê-la separada do original).

“Alguém poderia fazer um fork, se fosse necessário, caso algo saísse completamente do controle”, diz Nalley. O protocolo de comunicação de agentes da IBM, na verdade, surgiu a partir do MCP.

A Anthropic ainda está decidindo exatamente como desenvolver o MCP. Por enquanto, trabalha com um comitê de orientação composto por empresas externas que ajudam a tomar decisões sobre o desenvolvimento do MCP, mas a Anthropic parece aberta a mudar essa abordagem. “Estamos procurando evoluir a forma como pensamos sobre propriedade e governança no futuro”, diz Chu.

A linguagem natural é rápida o suficiente?

O MCP e o A2A funcionam nos termos dos sistemas: eles usam palavras e frases (chamadas de linguagem natural em IA), assim como os modelos de IA fazem ao responder a uma pessoa. Esse é um dos pontos de venda desses protocolos, pois significa que o modelo não precisa ser treinado para se comunicar de uma maneira que seja artificial para ele. “Permitir que

uma interface em linguagem natural seja usada entre os sistemas e não apenas com humanos desbloqueia o compartilhamento da inteligência que está incorporada nesses modelos”, diz Surapaneni.

No entanto, essa escolha traz desvantagens. Interfaces de linguagem natural carecem da precisão das APIs, o que pode resultar em respostas incorretas. Além disso, cria ineficiências.

Normalmente, um modelo de IA lê e responde ao texto dividindo as palavras em tokens, quando se quebra dados em pedaços menores. O modelo de IA lerá uma solicitação, dividirá em tokens de entrada, gerará uma resposta na forma de tokens de saída e, em seguida, colocará esses tokens em palavras para enviar de volta. Esses tokens definem, de certa forma, o quanto de trabalho o modelo de IA precisa fazer. Por isso, a maioria das plataformas de IA cobra dos usuários com base no número de tokens utilizados.

Mas o objetivo de trabalhar com tokens é justamente permitir que as pessoas compreendam a saída. Geralmente, é mais rápido e eficiente para a comunicação máquina-a-máquina trabalhar apenas com código. O MCP e o A2A funcionam com linguagem natural, o que faz com que o modelo precise gastar tokens enquanto o agente interage com outras máquinas, como ferramentas e outros sistemas. O usuário nem sequer vê essas trocas: todo o esforço para tornar tudo legível para humanos nunca é realmente lido por uma pessoa. “Você desperdiça muitos tokens se quiser usar o MCP”, diz Chen.

Chen descreve esse processo como potencialmente muito custoso. Por

exemplo, suponha que o usuário queira que o agente leia um documento e o resuma. Se o agente usar outro programa para fazer o resumo, ele precisa ler o documento, enviar o documento para o programa, ler o resumo de volta e enviá-lo novamente ao usuário. Como o agente precisou ler e escrever tudo, tanto o documento quanto o resumo são duplicados. De acordo com Chen, “na verdade, são muitos tokens.”

Como acontece com muitos aspectos dos designs do MCP e do A2A, seus benefícios também geram novos desafios. “Ainda há um longo caminho a percorrer se quisermos escalar e realmente torná-los úteis”, diz Chen. ■

