


INTELIGÊNCIA ARTIFICIAL

IA em escala: distribuição de agentes pode gerar débito técnico



Quando o piloto vira rotina, governança e observabilidade passam a definir o valor do uso corporativo.

Partir da ideia e chegar à prática é mais complexo do que parece. Quando a Inteligência Artificial entra nas empresas, ela costuma se mostrar como um piloto bem delimitado, com objetivos claros e poucos sistemas envolvidos. O verdadeiro desafio começa quando a IA passa a operar dentro do processo real, conectada a sistemas diferentes, com dados que variam em qualidade e com exceções que não estavam nos testes. É aí que o piloto vira operação, e a operação exige método para ser sustentada.

A distância entre teste e rotina surge quando a IA deixa de ser apenas uma camada de recomendação e passa a executar tarefas. Rodrigo Soares, Gerente de Soluções para Arquitetura LATAM na OutSystems, explica que “no momento em que o agente começa a escrever em sistemas, aprovar fluxos ou acionar ferramentas externas, ele deixa de ser assistente e passa a ser ator operacional, que precisa de governança”. Por isso, ao escalar um piloto, a conversa sai da lógica de provar que a IA funciona e passa a refletir sobre a garantia de que ela opere de forma estável, com previsibilidade e responsabilidade.

“No momento em que o agente começa a escrever em sistemas, aprovar fluxos ou acionar ferramentas externas, ele deixa de ser assistente e passa a ser ator operacional, que precisa de governança”

- Rodrigo Soares, Gerente de Soluções para Arquitetura LATAM na OutSystems

A conta que o piloto empurra para depois

A escala não costuma falhar por falta de capacidade da IA, mas sim pelo atrito com o ambiente em que ela precisa operar. Quando o uso entra no dia a dia, a organização precisa lidar com variações de dados, exceções que não estavam previstas e integrações que exigem estabilidade, mesmo quando regras e sistemas mudam. Em um primeiro momento, essas adaptações podem parecer ajustes pontuais, mas em uma operação que não pode parar, cada remendo deixa consequências. O resultado é mais manutenção, evoluções mais caras e maior probabilidade de falhas caso aconteça uma mudança de contexto.

É nesse ponto que entra o chamado débito técnico: um conceito da engenharia de software que descreve o “custo adiado” de atalhos usados para acelerar entregas no curto prazo, mesmo que isso comprometa a qualidade estrutural do sistema. A conta não desaparece, apenas fica para depois. Ela retorna na forma de retrabalho, manutenção mais complexa e maior fragilidade, justamente quando o funcionamento precisa ser contínuo, previsível e auditável.

Além disso, esse preço postergado não aparece apenas na manutenção. Ele também se manifesta na forma como a organização enxerga, descreve e prioriza os riscos da IA. Sem um vocabulário compartilhado, cada área passa a nomear o problema de um jeito, e a governança perde comparabilidade. No estudo “The AI Risk Repository” (2024), liderado por Peter Slattery, pesquisador do MIT, os autores afirmam que a ausência de um entendimento comum sobre riscos de Inteligência Artificial “pode dificultar a capacidade de discutir, pesquisar e reagir a eles”, em tradução livre. Na versão atual, o repositório reúne mais de 1.700 riscos extraídos de dezenas de frameworks, um sinal de como a complexi-

dade cresce rapidamente quando cada time segue sem padrões comuns.

Como a automação pode elevar o patamar dos riscos

Quando a automação se espalha por diferentes áreas, um erro que antes ficaria restrito a um ponto pode ganhar grandes proporções. Em vez de existir uma única automação central, a empresa passa a ter que conviver com fluxos em paralelo, conectados a sistemas distintos e mantidos por times diferentes. Sem padrões comuns de validação, monitoramento e atualização, até mudanças simples, como ajustar uma regra ou corrigir uma falha, exigem revisões em várias dessas rotinas ao mesmo tempo.

O risco fica ainda mais claro quando um agente assume a execução dessas sequências de passos. Como ele lê informações, toma decisões e avança etapa por etapa sem revisão humana a cada ação, um desvio pequeno no início pode atravessar todo o processo e só aparecer no final, quando já afetou cadastros, comunicações, registros ou indicadores da operação.

Esse tipo de fragilidade é aprofundado no estudo “Challenges and Paths Towards AI for Software Engineering”, publicado pelo MIT CSAIL em 2025, que argumenta que a barreira para usar IA em escala está menos em gerar código e mais em sustentar sistemas reais ao longo do tempo. Entre os gargalos mais relevantes para esse contexto estão a distância entre o que as avaliações controladas conseguem medir e o que acontece em bases reais, além da dificuldade de conduzir mudanças longas em repositórios grandes, com muitas dependências e necessidade de validação confiável.

Por isso, em produção, confiabilidade deixa de ser um refinamento técnico e vira condição op-

“Quando um agente assume a execução [...] um desvio pequeno no início pode atravessar todo o processo e só aparecer no final”

eracional. Rodrigo Soares reforça que um agente corporativo precisa operar com “escopo de atuação claramente delimitado” e, sobretudo, com “trilhas de auditoria e observabilidade contínua”. E ainda mais importante é que essas medidas estejam presentes desde o primeiro dia da operação, já que sem isso perde-se a capacidade de antecipar desvios, corrigir rotas e responder com evidências quando algo sai do esperado.

Em processos de missão crítica e em setores regulados, essa exigência sobe de patamar, porque não se trata apenas de reduzir retrabalho ou ganhar eficiência, mas de sustentar decisões e ações com rastreabilidade, auditoria e capacidade de resposta a incidentes, já que o custo de um afastamento do comportamento esperado pode envolver impacto financeiro, exigências legais e dano reputacional.

Plataforma como disciplina e shadow AI como sintoma

Quando agentes autônomos começam a tomar decisões, a discussão muda de eixo. Como afirma Rodrigo, a pergunta deixa de ser “funciona?” e passa a ser “quem controla? Quem audita? Quem responde pelo erro?”. Nesse contexto, a questão é onde essa governança se sustenta na rotina. À medida que mais áreas são automatizadas, cresce o número de fluxos em paralelo, muitas vezes criados com ferramentas que per-

mitem montar automações com menos dificuldade, conectando sistemas e dados com pouca ou nenhuma programação, fora de um projeto centralizado e sem revisão prévia de segurança.

“A resposta a esse cenário [Shadow AI] passa por construir uma base comum que permita acelerar sem perder governabilidade”

Quando a necessidade de resolver problemas rapidamente supera os processos formais, a shadow AI surge como um atalho. O termo se refere a iniciativas de IA que passam a operar fora do campo de visão da governança, criadas e colocadas em uso diretamente pelas áreas para ganhar velocidade. Em geral, esse movimento aparece quando existe um descompasso entre a pressão por agilidade e a capacidade da organização de entregar com controle. O resultado é um ambiente com pouca clareza sobre o que está em execução, quais dados são utilizados, quem tem acesso e como alterações são realizadas, além de ampliar o risco de exposição de informações sensíveis.

A resposta a esse cenário passa por construir uma base comum que permita acelerar sem perder governabilidade. Aqui, plataforma significa um conjunto unificado de padrões, integrações, políticas e mecanismos operacionais que facilitam a gestão. Isso inclui validação, registro do que foi executado, controle de acesso e monitoramento, todos incorporados ao modo como fluxos e agentes são criados e colocados em produção. Na prática, a maturidade aparece quando a organização preserva a integridade do sistema, man-

tém rastreabilidade do que foi feito, garante auditabilidade das decisões e tem observabilidade suficiente para detectar desvios e corrigir o curso.

Do piloto ao valor

Escalar com método exige disciplina de portfólio. Em vez de tratar cada piloto como vitória isolada, a organização precisa encará-los como decisões que têm ciclo de vida, custo de manutenção e risco associado. Sem esse filtro, o que era experimento se torna estoque permanente de exceções, acumulando débito técnico e ampliando a superfície de risco.

Na prática, essa disciplina significa separar três destinos possíveis para cada caso de uso. Alguns devem virar capacidade estável, com responsável claro, padrões de operação, monitoramento e rotina de mudança bem definida. Outros precisam de reengenharia antes de avançar, porque ainda não têm integrações confiáveis, validações suficientes ou evidência operacional para sustentar o uso contínuo. E há aqueles que devem ser encerrados, não por falha da tecnologia, mas porque o custo de manter e governar supera o valor gerado, ou porque o risco não se justifica.

Sobre boas práticas na transição do piloto para a escala, Rodrigo Soares, da OutSystems, diz que a virada acontece quando a empresa trata o experimento como padrão corporativo. “Escalar IA não é multiplicar casos de uso. É institucionalizar um modelo seguro, mensurável e sustentável. Quando isso acontece, a padronização deixa de ser controle e passa a ser acelerador”. Isso porque ela reduz dispersão, dá visibilidade ao que está em operação e cria um caminho mais previsível para ampliar o uso, sem transformar velocidade em fragilidade.